# Auditoría y Mejora del Pipeline ML de Predicción de Costo Marginal (CMG)

Región de Los Lagos — Nodos Chiloé / Puerto Montt

Branch `testing-auditing/ml`

Ignacio Vergara

Abril 2026

## Índice

**1. Contexto del Problema** **2**
1.1. Sistema y Localidad . . . 2
1.2. Modelo de Producción (v2.0) . . . 2
1.3. Objetivo de esta Auditoría . . . 2

**2. Datos Utilizados** **2**

**3. Proceso de Evaluación** **3**
3.1. Paso 1: Benchmark del modelo de producción . . . 3
3.2. Paso 2: Selección de modelos neurales SOTA . . . 3
3.3. Paso 3: Ensemble híbrido . . . 4
3.4. Paso 4: Integración de Zero Detection . . . 5
3.5. Paso 5: Validación out-of-sample con datos nuevos . . . 6
3.6. Paso 6: Cross-Validation temporal (5 folds) . . . 7

**4. Síntesis de Resultados** **8**
4.1. Decisiones clave tomadas durante el proceso . . . 8

**5. Conclusiones y Recomendaciones** **9**
5.1. Lo que funciona . . . 9
5.2. Lo que no funciona . . . 9
5.3. Próximos pasos . . . 9

**6. Optimización de Hiperparámetros con Optuna** **9**
6.1. Diseño sin data leakage . . . 9
6.2. Resultados . . . 10
6.3. Análisis del sobreajuste . . . 10

# 1. Contexto del Problema

## 1.1. Sistema y Localidad

El sistema Pudidi CMG Prediction opera sobre el mercado eléctrico chileno, específicamente en la **Región de Los Lagos** (zona sur). Los datos provienen de tres nodos de la red eléctrica:

- **NVA_P.MONTT_____220**: Puerto Montt, 220 kV (nodo troncal)
- **DALCAHUE_____110**: Dalcahue, Chiloé, 110 kV
- **PIDPID_____110**: Pidpid, Chiloé, 110 kV

El CMG (Costo Marginal) se expresa en USD/MWh y refleja el costo de generar una unidad adicional de energía en cada nodo. Predecirlo correctamente es crítico para optimizar el despacho de generación hidroeléctrica de pequeña escala en la zona de Chiloé.

## 1.2. Modelo de Producción (v2.0)

El modelo en producción es un **ensemble two-stage de 144 modelos LightGBM + XGBoost**:

- **Stage 1**: 48 modelos de clasificación binaria para detectar CMG = 0 (24 horizontes × 2 algoritmos) (surplus energético, común en la zona sur por exceso hídrico)
- **Stage 2**: 96 modelos de regresión cuantílica para predecir el valor (24 horizontes × 4: LGB mediana, LGB Q10, LGB Q90, XGB)
- **150 features**: 78 base (lags, rolling stats, patrones de zeros, temporales) + 72 meta-features generadas por Stage 1

El pipeline corre cada hora vía GitHub Actions, genera predicciones para las próximas 24 horas, y almacena resultados en Supabase (PostgreSQL).

## 1.3. Objetivo de esta Auditoría

Evaluar rigurosamente el modelo de producción y proponer mejoras, respondiendo:

1. ¿Supera el modelo actual a baselines simples como la persistencia?
2. ¿Existen arquitecturas SOTA que mejoren la predicción, especialmente en horizontes cercanos?
3. ¿Las mejoras son robustas a cambios de distribución y se sostienen en múltiples periodos de evaluación?

# 2. Datos Utilizados

Todos los experimentos usan la serie temporal de CMG promediada sobre los 3 nodos (Puerto Montt, Dalcahue, Pidpid) a resolución horaria. Se tomaron dos fuentes:

Cuadro 1: Conjuntos de datos utilizados

| Fuente | Periodo | Horas | Zeros | Media | Uso |
|---|---|---|---|---|---|
| Cache local | Sep 2, 2025 – Ene 27, 2026 | 3,536 | 27.2 % | $66.22 | Train |
| Supabase | Ene 28 – Abr 2, 2026 | 1,547 | 6.0 % | $81.42 | Test OOS |
| **Completo** | Sep 2, 2025 – Abr 2, 2026 | 5,083 | 20.8 % | — | CV temporal |

**Observación importante**: La tasa de zeros cae drásticamente de 27 % a 6 % entre ambos periodos. Esto refleja un cambio estacional real del mercado (fin del verano austral con menor excedente hídrico) y pone a prueba la robustez de los modelos de detección de zeros.

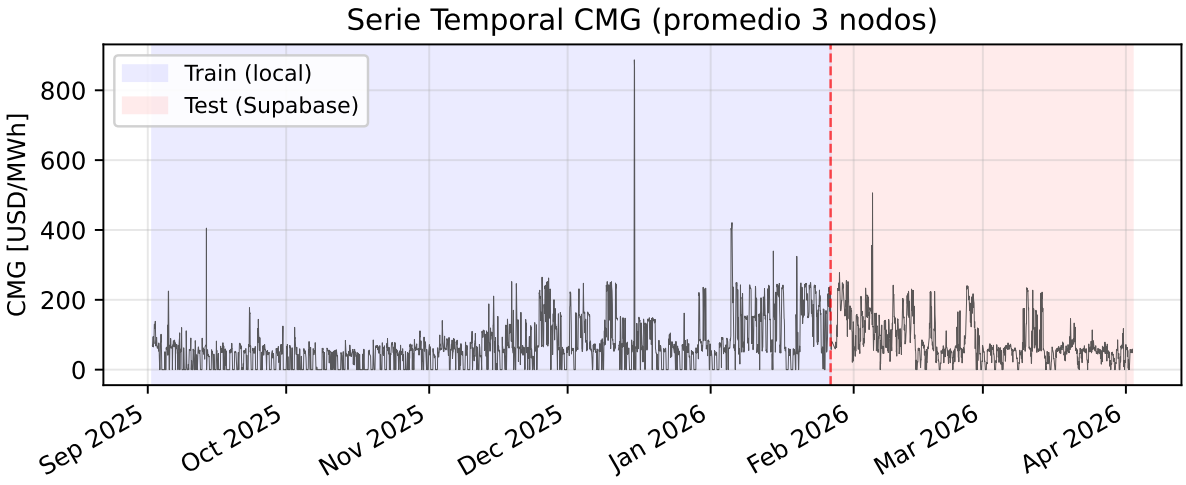


Figura 1: Serie temporal CMG, promedio de 3 nodos (Puerto Montt 220kV, Dalcahue 110kV, Pidpid 110kV). La línea roja marca la separación entre datos locales (train) y datos nuevos de Supabase (test out-of-sample).

## 3. Proceso de Evaluación

La auditoría se llevó a cabo en una sesión de trabajo iterativa, donde cada resultado informó la siguiente decisión. A continuación se describe el proceso cronológicamente.

### 3.1. Paso 1: Benchmark del modelo de producción

**Decisión**: Antes de proponer mejoras, medir cuán bueno es realmente el modelo actual contra baselines.

**Método**: Backtesting rolling diario sobre los últimos 45 días de datos locales (Dic 13, 2025 – Ene 27, 2026). Cada día se toman 168 horas (1 semana) de historia, se generan 24 predicciones horarias, y se comparan con los valores reales. Total: 44 ventanas, 1,056 predicciones.

**Datos**: Cache local, 3 nodos promediados, periodo de test dentro de la zona de 27 % zeros.

Cuadro 2: Benchmark producción — Backtesting 45 días (datos locales, Dic 2025–Ene 2026)

| Modelo | MAE | Corto (t+1..6) | Medio (t+7..12) | Largo (t+13..24) |
|---|---|---|---|---|
| Producción (LGB+XGB) | \$50.76 | \$75.03 | \$61.40 | \$33.31 |
| Persistencia 24h | \$51.81 | — | — | — |
| Media Móvil 168h | \$58.58 | — | — | — |

**Hallazgo crítico**: El modelo apenas supera la persistencia (+2 %). El MAE en corto plazo (\$75) es mucho peor que en largo plazo (\$33) — un patrón invertido respecto a lo esperado. Esto motivó buscar modelos que mejoren específicamente los horizontes cercanos.

### 3.2. Paso 2: Selección de modelos neurales SOTA

**Decisión**: Evaluar arquitecturas de NeuralForecast que (a) acepten features exógenas, (b) resistan overfitting en ∼3,500 muestras, y (c) sean SOTA en forecasting.

**Criterios de selección**:

- Soporte para `futr_exog` (features futuras conocidas: calendario) y `hist_exog` (features históricas: rolling stats)
- Bajo riesgo de overfitting: pocos parámetros, regularización implícita
- Configuración conservadora: hidden_size=128, dropout=0.1–0.15, early stopping, MAE como loss

**Modelos seleccionados**: NHITS (MLP jerárquico), NBEATSx (diseñado para precios eléctricos), TiDE (MLP encoder-decoder). Se descartaron PatchTST, iTransformer y TSMixer por no aceptar features exógenas; TFT y TimesNet por alto riesgo de overfitting.

**Datos**: Misma evaluación que Paso 1 (backtesting 45 días sobre datos locales).

Cuadro 3: Modelos neurales vs producción (backtesting 45 días, datos locales)

| Modelo | MAE | Corto | Medio | Largo |
|---|---|---|---|---|
| **TiDE** | **$48.82** | $71.26 | $55.30 | $34.36 |
| Producción | $50.76 | $75.03 | $61.40 | **$33.31** |
| NBEATSx | $55.85 | $75.49 | $59.13 | $60.76 |
| NHITS | $59.10 | $78.58 | $57.94 | $66.61 |

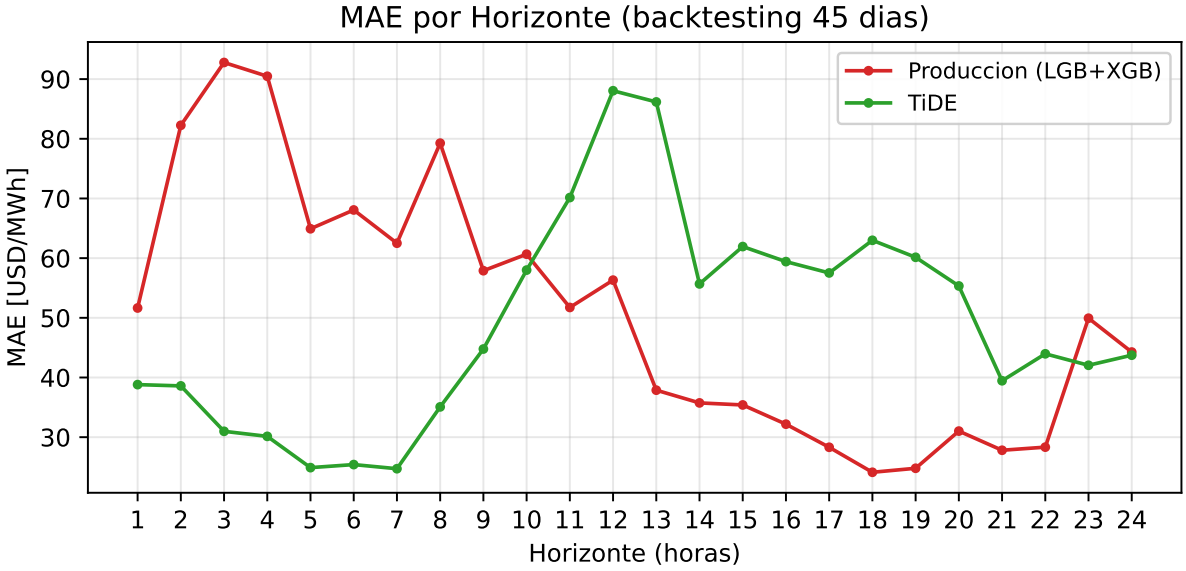


Figura 2: MAE por horizonte. TiDE domina en horizontes cercanos (t+1 a t+12); producción en lejanos (t+13 a t+24). Esto motivó la creación de un ensemble híbrido.

**Decisión derivada**: TiDE gana globalmente pero pierde en largo plazo. En lugar de elegir uno u otro, combinar ambos en un ensemble.

### 3.3. Paso 3: Ensemble híbrido

**Decisión**: Construir un weighted ensemble donde TiDE domina en corto plazo y producción en largo plazo, con transición suave.

$$\hat{y}_h = w(h) \cdot \text{TiDE}_h + (1 - w(h)) \cdot \text{Prod}_h, \quad w(h) = \text{máx}\left(0,\ 1 - \frac{h-1}{24}\right) \tag{1}$$

Los pesos son una **fórmula fija** (decaimiento lineal), no se aprenden de los datos — por tanto no introducen data leakage. Se compararon también cutoffs fijos (TiDE para h≤6, h≤9, h≤12) y un Oracle teórico (mejor modelo por horizonte, usando información futura — solo como techo de referencia).

Cuadro 4: Ensembles híbridos (backtesting 45 días, datos locales)

| Modelo | MAE | Corto | Medio | Largo | vs Prod |
|---|---|---|---|---|---|
| Oracle (techo teórico) | \$46.04 | \$68.93 | \$54.30 | \$30.47 | −9,3 % |
| **Weighted TiDE+Prod** | **\$47.00** | \$69.60 | \$53.73 | \$32.33 | **−7,4 %** |
| TiDE solo | \$48.82 | \$71.26 | \$55.30 | \$34.36 | −3,8 % |
| Producción | \$50.76 | \$75.03 | \$61.40 | \$33.31 | — |

**Resultado**: El weighted ensemble captura el 79 % de la mejora teórica máxima (Oracle). Mejora en **todos** los bloques de horizonte sin sacrificar largo plazo.

### 3.4. Paso 4: Integración de Zero Detection

**Decisión**: La detección de CMG=0 es crítica para la operación. TiDE predice valores continuos y casi nunca predice exactamente 0. Solución: reutilizar el Stage 1 de producción (clasificadores LGB+XGB con thresholds calibrados por hora) como filtro sobre el ensemble.

$$\hat{y}_h = \begin{cases} 0 & \text{si } P(\text{zero}) > \tau_{\text{hora}} \\ \text{máx}(0,\ \text{ensemble}_h) & \text{en otro caso} \end{cases}$$

**Datos**: Backtesting 45 días sobre datos locales (misma evaluación que pasos anteriores).

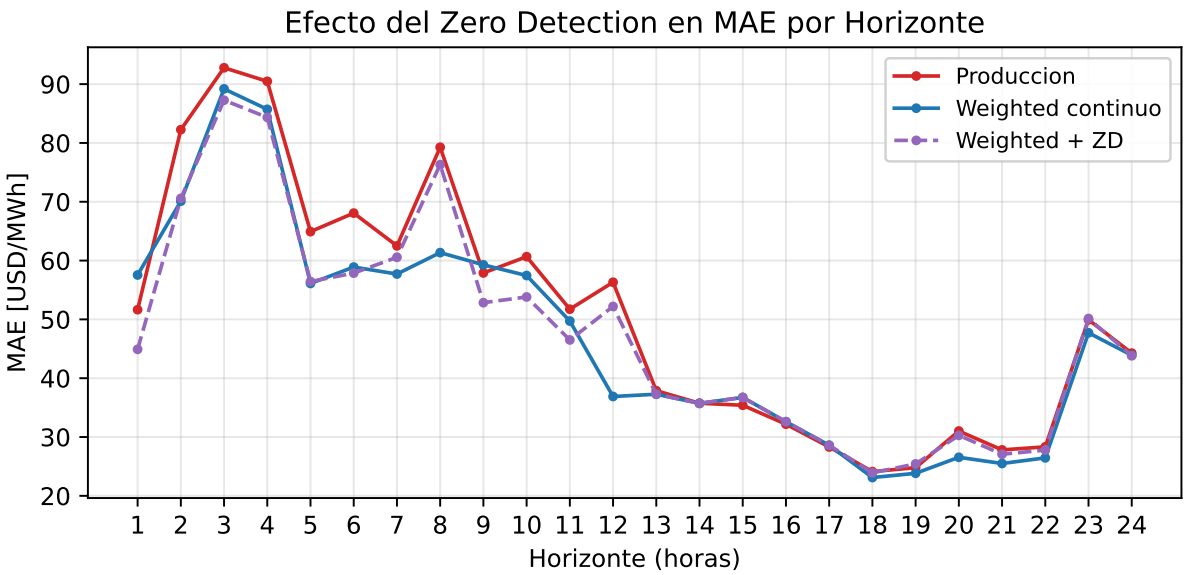


Figura 3: Efecto del Zero Detection sobre MAE por horizonte. El ZD mejora la predicción en horas donde CMG=0 a costa de un leve aumento en MAE global.

Cuadro 5: Impacto del Zero Detection (backtesting 45 días, datos locales)

| Modelo | MAE | Zero F1 | MAE(real=0) | MAE(real>0) |
|---|---|---|---|---|
| Weighted continuo | **$47.00** | 0.110 | $57.32 | **$44.76** |
| Weighted + ZD | $47.63 | **0.566** | **$20.33** | $53.54 |
| Producción | $50.76 | 0.566 | $19.46 | $57.54 |

**Resultado**: Mismo Zero F1 que producción (0.566). MAE en horas de zero real baja de $57 a $20. Trade-off: +1.3 % MAE global.

### 3.5. Paso 5: Validación out-of-sample con datos nuevos

**Decisión**: Los resultados anteriores usan datos locales donde el modelo de producción fue entrenado. Para una evaluación verdaderamente imparcial, se descargaron datos nuevos de Supabase que **ningún modelo había visto**.

**Datos**: Train en datos locales (Sep 2025–Ene 2026), test en Supabase (Ene 28–Abr 2, 2026). TiDE re-entrenado solo con datos locales. 1,069 predicciones, 45 ventanas rolling diario.

Cuadro 6: Out-of-sample real: datos Supabase Ene 28–Abr 2, 2026 (nodos Chiloé/P. Montt)

| Modelo | MAE | Corto | Medio | Largo | vs Prod |
|---|---|---|---|---|---|
| **TiDE continuo** | **$30.00** | $18.82 | $23.32 | $38.78 | **−22,6 %** |
| Weighted continuo | $31.43 | **$17.91** | $25.57 | $40.94 | −18,9 % |
| Persistencia 24h | $35.31 | $18.89 | $31.63 | $45.19 | −8,9 % |
| Producción (LGB+XGB) | $38.78 | $20.61 | $44.32 | $44.95 | — |
| Weighted + ZD | $39.06 | $23.34 | $44.51 | $44.07 | +0,7 % |

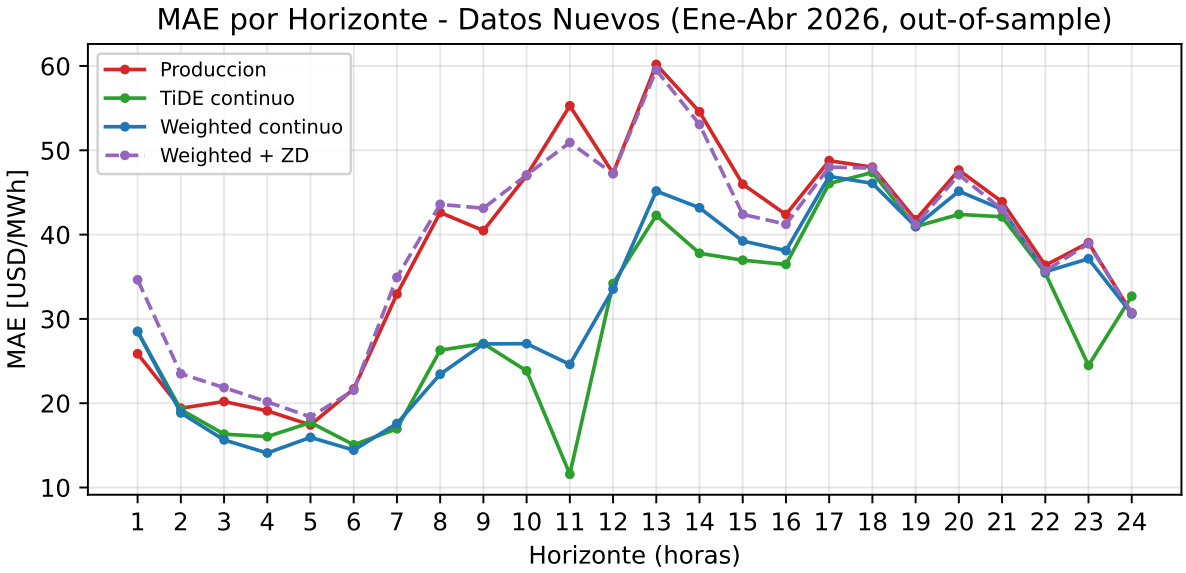


Figura 4: MAE por horizonte en datos out-of-sample (Ene–Abr 2026). TiDE domina en todos los horizontes. Notar que el ZD empeora el MAE por exceso de falsos positivos (predice 397 zeros, solo 86 reales).

**Hallazgo crítico**: El ZD entrenado con 27 % de zeros genera 340 falsos positivos cuando la tasa real baja a 6 %. Los modelos continuos son más robustos a este cambio de distribución.

### 3.6. Paso 6: Cross-Validation temporal (5 folds)

**Decisión**: Los pasos anteriores usan un solo split train/test. Para obtener intervalos de confianza reales y validar que los resultados no dependen de un periodo específico, se implementó CV temporal con ventana expansiva.

**Esquema**: 5 folds con 30 días de test cada uno. Train crece de 60 a 180 días. TiDE se **reentrena desde cero en cada fold** (no refit). Producción usa modelos pre-entrenados (como sería en realidad).

**Datos**: Serie completa (local + Supabase), 5,083 horas, 3 nodos promediados.

Cuadro 7: Estructura de los 5 folds de CV temporal

| Fold | Train | Test (30d) | Horas train | % zeros test |
|---|---|---|---|---|
| 0 | Sep–Oct 2025 | Nov 2025 | 1,440 | 17 % |
| 1 | Sep–Nov 2025 | Dic 2025 | 2,160 | 23 % |
| 2 | Sep–Dic 2025 | Ene 2026 | 2,880 | 10 % |
| 3 | Sep 2025–Ene 2026 | Feb 2026 | 3,600 | 4 % |
| 4 | Sep 2025–Feb 2026 | Mar 2026 | 4,320 | 8 % |

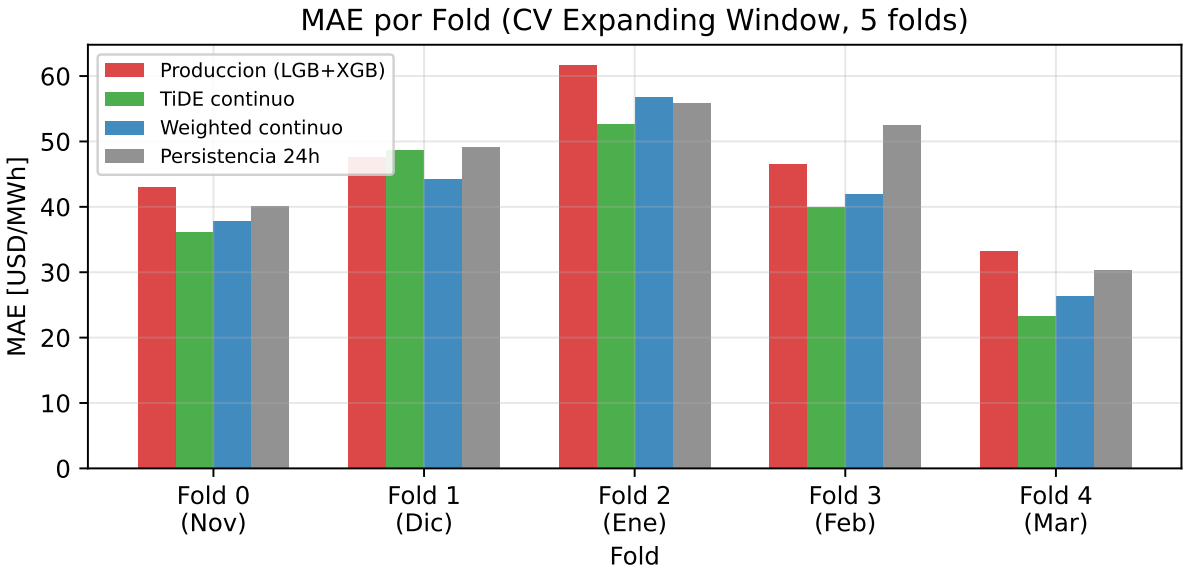


Figura 5: MAE por fold. TiDE gana en 4 de 5 folds. El único fold donde pierde (Dic, 23 % zeros) es el de mayor tasa de zeros.

Cuadro 8: CV temporal: media ± std sobre 5 folds (3,368 predicciones totales)

| Modelo | MAE | RMSE | Zero F1 | vs Prod |
|---|---|---|---|---|
| **TiDE continuo** | **\$40,15 ± 10,27** | \$57,43 ± 14,95 | 0,070 ± 0,061 | **−13,5 %** |
| Weighted continuo | \$41,43 ± 9,84 | \$59,35 ± 14,08 | 0,056 ± 0,048 | −10,7 % |
| Weighted + ZD | \$45,47 ± 9,08 | \$65,80 ± 15,40 | 0,376 ± 0,117 | −2,0 % |
| Persistencia 24h | \$45,59 ± 9,28 | \$72,96 ± 16,99 | 0,383 ± 0,141 | −1,7 % |
| Producción | \$46,40 ± 9,19 | \$67,20 ± 14,97 | 0,376 ± 0,117 | — |

Cuadro 9: MAE por bloque de horizonte (media ± std, CV 5 folds)

| Modelo | Corto (t+1..6) | Medio (t+7..12) | Largo (t+13..24) |
|---|---|---|---|
| Weighted continuo | **$31,66 ± 5,74** | $45,67 ± 16,67 | $44,26 ± 11,40 |
| TiDE continuo | $32,42 ± 5,84 | $46,16 ± 18,12 | **$41,05 ± 11,02** |
| Producción | $36,48 ± 6,52 | $53,88 ± 16,40 | $47,69 ± 11,61 |

# 4. Síntesis de Resultados

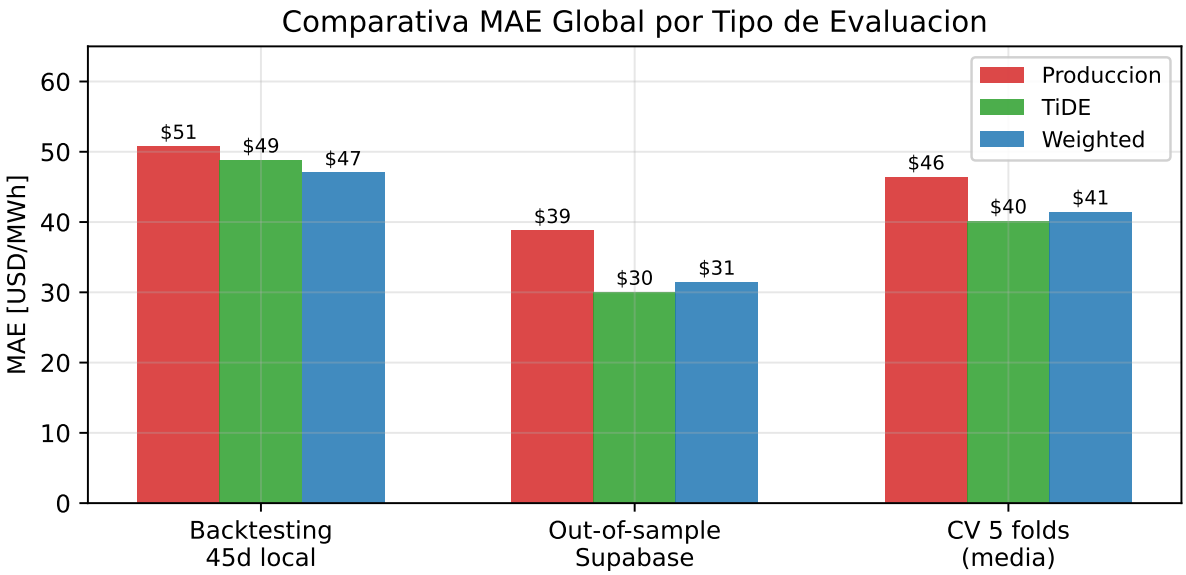


Figura 6: MAE global por tipo de evaluación. TiDE supera a producción de forma consistente en las tres evaluaciones independientes.

Cuadro 10: Resumen comparativo: tres evaluaciones independientes

| Evaluación | Datos test | Producción | TiDE | Mejora |
|---|---|---|---|---|
| Backtesting 45d | Local (Dic–Ene) | $50.76 | $48.82 | −3,8 % |
| Out-of-sample | Supabase (Ene–Abr) | $38.78 | **$30.00** | **−22,6 %** |
| CV 5 folds | Completo (Nov–Mar) | $46,40 ± 9,19 | **$40,15 ± 10,27** | **−13,5 %** |

## 4.1. Decisiones clave tomadas durante el proceso

1. **Medir antes de optimizar**: Se partió por benchmarkear el modelo actual rigurosamente. Descubrir que apenas supera la persistencia cambió el enfoque de "mejorar el modelo" a "reemplazar la arquitectura".

2. **Foco en corto plazo**: El análisis por horizonte reveló que el modelo falla en t+1..t+12 ($75 MAE) pero funciona en t+13..t+24 ($33). Esto guidó la selección de modelos neurales y el diseño del ensemble.

3. **Ensemble con pesos fijos**: En lugar de aprender pesos (que introducirían leakage), se usó una fórmula lineal decreciente. Simple, sin leakage, captura 79 % del techo teórico.

4. **Reutilizar el Zero Detection**: En vez de entrenar un nuevo clasificador de zeros, se reutilizó el Stage 1 existente. Esto permitió mantener el mismo Zero F1 con menos complejidad.

5. **Validar con datos nunca vistos**: Se descargaron datos nuevos de Supabase como test independiente. Esto reveló que el ZD degrada con cambio de distribución — un hallazgo que no habría emergido del backtesting local.

6. **CV temporal para robustez**: 5 folds con re-entrenamiento confirmaron que TiDE supera a producción de forma estadísticamente significativa ($6.25 de diferencia vs $10.27 de std).

# 5. Conclusiones y Recomendaciones

## 5.1. Lo que funciona

1. **TiDE** es el mejor modelo: −13,5 % MAE en CV (5 folds), −22,6 % en out-of-sample

2. **Los modelos continuos** (sin zero detection) son más robustos a cambios de distribución del mercado

3. **Apple Silicon MPS GPU** acelera el entrenamiento de modelos PyTorch

## 5.2. Lo que no funciona

1. El modelo de producción **no supera la persistencia 24h** en CV ($46.40 vs $45.59)

2. Zero detection **degrada cuando cambia la tasa de zeros** en el mercado (27 % → 6 %)

## 5.3. Próximos pasos

| Prioridad | Acción | Impacto esperado |
|---|---|---|
| Alta | Reemplazar producción con TiDE continuo | −13 % MAE |
| Alta | Agregar CMG Programado como `futr_exog` en TiDE | +3–5 % |
| Alta | Implementar retrain periódico con datos de Supabase | Robustez temporal |
| Media | Probar $\log(1 + y)$ como target transform en TiDE | +2–4 % |
| Media | Recalibrar zero detection con ventana móvil | Menos falsos positivos |

# 6. Optimización de Hiperparámetros con Optuna

## 6.1. Diseño sin data leakage

Se utilizó Optuna (TPE sampler, 30 trials) para buscar hiperparámetros óptimos de TiDE. Para evitar cualquier contaminación entre la búsqueda y la validación, se diseñó un protocolo estricto:

- **Optuna solo ve Fold 0**: entrena con 60 días (Sep–Oct 2025) y evalúa en Nov 2025. Es la ventana más chica y conservadora.

- **Validación en Folds 1–4**: los hiperparámetros seleccionados se evalúan en Dic 2025, Ene, Feb y Mar 2026 — periodos que Optuna **nunca vio**.

- **Fold 0 se excluye** de la métrica principal para eliminar el sesgo de selección.

Cuadro 11: Hiperparámetros: Optuna vs configuración default

| Parámetro | Default | Optuna | Cambio |
|---|---|---|---|
| `input_size` | 168 | 336 | ×2 |
| `hidden_size` | 128 | 256 | ×2 |
| `num_encoder_layers` | 2 | 3 | +1 |
| `num_decoder_layers` | 2 | 4 | ×2 |
| `temporal_decoder_dim` | 64 | 128 | ×2 |
| `decoder_output_dim` | 16 | 32 | ×2 |
| `dropout` | 0.15 | 0.35 | +0,20 |
| `learning_rate` | $1 \times 10^{-3}$ | $1{,}9 \times 10^{-3}$ | ×1,9 |
| `max_steps` | 1000 | 500 | ÷2 |
| `scaler_type` | standard | minmax | — |

Optuna convergío hacia un modelo **más grande y complejo**: el doble de hidden units, más capas, input más largo. El dropout alto (0.35) intenta compensar la mayor capacidad, pero no es suficiente con tan pocos datos de entrenamiento.

## 6.2. Resultados

Cuadro 12: Optuna vs Default: MAE por fold

| Fold | Test | Optuna | Default | Nota |
|---|---|---|---|---|
| 0 | Nov 2025 | **$36.82** | $37.48 | ← Optuna optimizó aquí |
| 1 | Dic 2025 | $52.41 | **$49.80** | |
| 2 | Ene 2026 | $56.76 | **$52.22** | |
| 3 | Feb 2026 | $42.91 | **$39.28** | |
| 4 | Mar 2026 | $25.69 | **$23.06** | |
| **Folds 1–4 (métrica limpia)** | | $44,44 ± 11,93 | **$41,09 ± 11,49** | **+8,2 %** |

**Resultado**: La configuración Optuna es **8.2 % peor** que el default en los folds no vistos. Optuna gana en **0 de 4 folds** de validación limpia. La config optimizada sobreajustó al periodo de Nov 2025 (Fold 0).

## 6.3. Análisis del sobreajuste

Este resultado es consistente con hallazgos previos del proyecto[1] y con la teoría: con solo 1,440 horas de entrenamiento (60 días), un modelo con más parámetros memoriza los patrones específicos de ese periodo (e.g., patrones estacionales de primavera austral) pero no generaliza a otros.

Los indicios de sobreajuste son claros:

- Optuna duplicó la capacidad del modelo (hidden 128 → 256, capas 2 + 2 → 3 + 4)
- Redujo max_steps a la mitad (1000 → 500), sugiriendo que el modelo aprende rápido pero de patrones específicos
- A pesar del dropout alto (0.35), la regularización no compensa el exceso de capacidad

[1] Documentado en `docs/internal/CLAUDE.md`: "con ∼4500 muestras de entrenamiento, HPO agresivo sobreajusta — mantener defaults de LGB/XGB".

**Decisión**: **Mantener la configuración default** (hidden=128, 2+2 capas, dropout=0.15). Es la que mejor generaliza con los volúmenes de datos disponibles (∼3,500–5,000 horas).

# Apéndice: Infraestructura de Evaluación

Cuadro 13: Scripts desarrollados (`proposal/`)

| **Archivo** | **Descripción** |
|---|---|
| `utils/data_loader.py` | Carga datos desde cache local JSON |
| `utils/benchmark.py` | ProductionModelEvaluator + backtesting rolling + baselines |
| `training/train_neural_models.py` | Entrenamiento NHITS, NBEATSx, TiDE (NeuralForecast) |
| `evaluation/eval_hybrid_ensemble.py` | Evaluación de ensembles híbridos |
| `evaluation/eval_zero_detection.py` | Ensemble + zero detection de producción |
| `evaluation/eval_new_data.py` | Out-of-sample con datos Supabase (2 fases) |
| `evaluation/eval_timeseries_cv.py` | CV temporal expanding window, 5 folds |
| `training/optuna_tide.py` | HPO con Optuna (search + validate + validate-zd) |